

대규모 언어모델의 주제별 편향과 모델 간 차이

Topic-Specific Bias and Inter-Model Differences in Large Language Models

최예나

Yena Choi

한양대학교 인공지능학과

Department of Artificial Intelligence

yenachoi@hanyang.ac.kr

한경식*

Kyungsik Han

한양대학교 데이터사이언스학과

Department of Data Science

kyungsikhan@hanyang.ac.kr

* 교신 저자

요약문

대규모 언어모델(LLM)은 인간 참가자를 대체하여 설문 조사를 쉽고 빠르게 진행하는 데에 큰 기여를 하고 있다. 이는 시간과 비용이 많이 드는 전통적인 설문조사의 제약점을 해결할 수 있다는 점에서 최근 관련 연구가 많아지고 있으며 그 중요도가 커지고 있다. 하지만 LLM 이 인간을 어느 정도까지 대체할 수 있는가에 대한 문제가 남아 있으며, LLM 과 인간 정렬에 관한 연구의 중요성도 함께 높아지고 있다. 이에 인간 참가자를 LLM 으로 대체할 가능성을 논하기 전에, 특정 조건에서 LLM 과 인간 여론 결과 분포와의 유사성을 파악하는 분포 정합성, 인간 여론 결과 분포와 LLM 응답 분포의 괴리로 발생 가능한 편향, LLM 의 종류에 따른 응답 차이 등을 점검하는 것이 중요하다. 본 논문에서는 LLM 편향을 LLM 별 및 주제별로 정량적으로 확인하여 사람의 의견을 대체하거나 설문조사를 대신할 때 편향이 어느 정도 존재할 수 있으며, 그에 대응하여 우리가 취해야 할 조치는 무엇인지 탐색한다. 본 연구는 네 가지 사회적으로 논란이 많은 주제인 안락사, 젠더, 동물 실험, 낙태에 대해 대표적인 LLM 인 GPT-4o-mini, Gemini-2.5-flash 와 인간간의 관점 차이를 정량적으로 비교하였다. 실험 결과, GPT-4o-mini 는 안락사와 젠더 주제에 대해 Gemini-2.5-flash 대비 여론조사 결과보다 찬성 쪽으로 유의미하게 편향되는 경향을 보였으며, Gemini-2.5-flash 는 동물실험 주제에 대해 GPT-4o-mini 대비 찬성 쪽으로 소폭 편향되는 경향을 보였다. 본 연구는 기존 논문에 대비해 편향을 구체적으로 파악하기 위해 주제별과 LLM 별로 분석하였다는 점에서 연구적 의의가 있다. 이러한 주제별 및 LLM 별 편향은 사람의 의견을 대체하거나 설문조사를 대신할 때 다양한 LLM 과 LLM family 를 활용하여 균형 잡힌 응답을 만들어야 한다는 점을 시사한다.

주제어

대규모 언어모델(LLM), 인간 정렬, LLM 편향

1 서론

대규모 언어모델(LLM)의 발전으로 인간 참가자를 대신하여 LLM 을 사용하는 연구가 증가하고 있다[1-3]. 이는 대규모 표본을 전통적인 설문조사보다 빠르고 적은 비용으로 생성할 수 있으며, 프롬프트로 사회인구학적 특성을 조건화해 특정 하위집단의 응답 패턴을 어느 정도 재현할 수 있기 때문에, 이러한 활용 가능성에 관한 후속 연구가 이어지고 있다[2]. 이렇게 만든 설문조사는 사회 과학적 측면에서 많은 활용이 가능하며, 그 활용성에 대해 많은 논의와 연구가 이루어지고 있는 중요한 연구 분야이다.

하지만 동시에 LLM 의 응답은 선택지의 문구나 구성, 순서, 척도 등 여러 요인에 민감하며, 미세 조정 후에도 인간 집단에 가까워지지 못하는 문제와 인간 표본 분포와 큰 차이가 난다는 문제가 보고된다[4]. 따라서, 인간 참가자를 대체하여 설문 조사를 진행하는 것을 논하기 전에, LLM 의 인간 분포 정렬을 체계적으로 연구하여 LLM 편향이 특정 인구 집단에 대한 불공정, 신뢰 악화, 오정보 확산 같은 사회적 위험으로 이어질 수 있는 가능성을 검토하고, 이를 사전에 방지하는 것이 중요하다[5]. 이를 위해, 최근 LLM 과 인간 정렬을 평가하는 여러 프레임워크가 제안되고 있다. 예시로, Santurkar et al.[5] 연구에서는 LLM 이 어떤 집단의 의견을 가장 크게 대체하는지를 탐구하여 특정 인간 집단과의 정렬을 정량화하였다. 이 연구의 저자들은 LLM 이 인간과 정렬되도록 피드백을 주어 미세 조정하였지만, 여전히 LLM 은 특정 인구 집단(예: 민주당 혹은 고학력 등)의 의견에 더 큰 비중을 두어, LLM 이 전체 인구를 대표하지 못함을 언급하였다.




그림 1. 대규모 언어모델의 주제별 편향과 LLM 별 차이를 파악하기 위한 세 단계. (a)에서 생성된 프롬프트를 (b) 단계에서 생성된 LLM 전문가 에이전트에게 입력하여 응답을 받고 찬성과 반대 개수를 집계하여 분포를 생성한다. (c) 단계에서는 주제에 대해 LLM 별로 응답을 비교한다. 그림에 서는 예시로 안락사를 주제로 선정하였다.

Dominguez-Olmedo et al.[4] 연구에서는 대표적인 LLM 들을 대상으로 설문 응답의 형식이나 순서에 따라 LLM 응답의 편향이 생김을 확인하였다. 그러나 이러한 선행 연구들은 LLM 편향을 주제별과 LLM 별로 정량적으로 확인하지 않았다는 점에서 연구적인 확장의 필요성이 드러났다. 이에 본 논문은 주제와 LLM 에 따라 LLM 의 응답 편향이 달라짐을 밝힘으로써 편향을 구체적으로 파악했다는 점에서 의미가 있다.

인간 참가자를 대체하여 LLM 으로 설문조사를 실행하기 전, LLM 에 따른 주제별 편향 정도가 어느 정도인지, 그리고 이러한 편향이 각 LLM 별로 얼마나 다르게 존재하는지 정량적으로 분석하는 것은 매우 중요하다. 특히, 정답이 없으며 사회적으로 의견이 분분한 주제에 대해 LLM 이 특정 의견으로 편향된 답을 주는 것은 인간 참가자를 대체할 근거가 부족함을 의미하며, 이러한 LLM 과 인간 분포와의 괴리는 사회적인 문제를 야기할 수 있다[5]. 이에 본 논문은 대표적인 LLM 인 GPT-4o-mini 와 Gemini-2.5-flash 가 사회적으로 논란이 되는 주제에 대해 사람의 응답과 어떠한 차이를 보여주는지를 알아보기 위해 다음과 같이 연구 질문을 설정하였다.

- Research Question (RQ): 사회적으로 논란이 되는 주제에 대해 각 LLM 은 사람의 응답과 차이점이 있는가?

우리는 실제 여론조사 결과와 LLM 의 응답을 비교하기 위해, 먼저 LLM 전문가 에이전트를 생성하였다. 전문가 에이전트 생성에는 다중 전문가 에이전트를 생성하고 응답을 받는 대표적인 프레임워크인 Multi-expert Prompting(MEP)[6]와 Multi-agent Debate[7] 중 전문가 에이전트들이 서로 토론하거나 반박하지 않고 독립적으로 각각의 의견을 출력하여 에이전트끼리의 영향을 배제한 MEP 를 사용하였다. MEP 논문에서는 세 명의 전문가 에이전트만으로도 단일 전문가 에이전트에 비해 덜 편향되고 더 정확도 높은 응답을 받을 수 있다고 주장하였기에 본 연구에서는 전문가 에이전트 50 명을 생성하였다[6]. 이후 MEP를 사용하여 만들어진 전문가 에이전트에게 질문하고 질문에 대한 찬성과 반대 비율로 응답 분포를 생성하였다. 예시로, 안락사 주제에 대해 찬성과 반대 여부를 집계하여, 전문가 에이전트 50 명 중 30 명이 찬성하였다면, 찬성 60%와 반대 40%로 응답 분포를 구성하였다. 이렇게 구성된 응답 분포를 실제 여론조사 결과와 비교하여 RQ 를 탐구하였다. 비교에는 두 표본비율 z-검정을 수행하여 어느 주제에서 어떤 LLM 이 편향을 가지는지에 대해 체계적으로 조사하였다. <그림 1>은

해당 연구 과정을 설명한다. 연구 결과, LLM 마다 특정 사회 주제에 대해 찬성으로 편향되는 정도가 달랐으며, 각각의 LLM 이 상이한 응답을 줄 수 있음을 발견하였다.

본 논문은 실제 LLM 의 편향 정도를 여론조사 결과와 비교하여 LLM 별, 그리고 주제별로 분석했다는 점에서 선행 연구와의 차별점을 둔다. 이는 향후 인간 참가자를 대체하여 LLM 으로 설문조사를 진행할 시 고려해야 할 사항 중 여러 LLM 을 사용하여 설문해야 한다는 것을 초기 발견으로 제시하였다는 점에서 의의가 있다.

2 사회적으로 논란이 되는 주제 선정

사회적으로 논란이 되며 찬성과 반대의 의견이 분분한 주제에 대해 다수의 LLM 전문가 에이전트가 찬성 또는 반대로 편향된 답변을 주는 것은 사회적으로 큰 문제가 될 수 있다[5]. 이에, 질문 주제 선정을 위해 미국 내에서 논란이 되는 사회 주제들 중 찬성과 반대 비율이 비교적 균형을 이루는 항목 네 가지를 선별하였다[8,9]. 근거 자료는 미국의 대표적인 통계조사 단체인 Gallup[8,9]의 미국 성인을 대상으로 한 여론 조사 결과를 중심으로 발췌하였으며, 여론 조사 결과의 요약은 아래 <표 1>에 제시하였다. 본 연구는 최종 선별된 네 가지 범주인 안락사, 젠더, 동물 실험, 그리고 낙태에 대해 프롬프트 문항 네 항목을 구성하였다.

표 1. 여론 조사 주요 결과

주제	안락사	젠더	동물 실험	낙태
찬성 %	53%	44%	47%	49%
비찬성%	47%	56%	53%	51%

3 데이터 수집

본 섹션에서는 선정된 네 가지 사회 주제를 가지고 문항을 생성한 방식과 실험에 사용된 LLM, 응답 생성 방식, 데이터 전처리 방법을 서술한다.

3.1 문항 생성

LLM 프롬프트 문항은 기존 여론조사 문항의 어휘, 구조, 응답 척도를 참고하여 표현과 응답 형식을 최대한 일치시키도록 설계하였다. 또한 동일한 조건에서 여론조사(이지선다 문제)와의 비교를 위해, 프롬프트 말미에 “You must pick one side.”를 추가하였다. 그럼에도 불구하고 LLM 이 응답을 회피한 경우가 발생한다면, 해당 시도는 무응답으로 간주하여 비찬성으로 분류하였다. <

그림 2>의 (1)은 여론조사를 참고하여 설계된 프롬프트이다.

3.2 사용 모델과 응답 생성 방식

데이터 수집을 위해 LLM 은 대표적인 LLM 인 GPT-4o-mini 와, Gemini-2.5-flash 를 사용하였으며, 이 모델들은 전문가 에이전트 생성, 응답 생성, 응답 집계 단계에서 사용되었다. 예를 들어, GPT-4o-mini 모델 사용 시, 전문가 에이전트와 응답 생성, 응답 집계 단계에서 모두 GPT-4o-mini 모델을 사용한다. 데이터 수집을 위해 선행 연구인 MEP 의 과정을 거쳐 전문가 에이전트와 전문가 에이전트들의 응답을 독립적으로 집계하였다. 각 LLM 은 동일한 프롬프트, 샘플링 설정과 토큰 예산 아래에서 비교하였으며, 일반화할 수 있는 측면을 고려해 전문가 에이전트 수는 $n=50$ 으로 설정하였다. <그림 2>의 (1)에 서술된 프롬프트를 입력으로 넣어 LLM 이 질문과 관련된 50 명의 전문가 에이전트를 생성하고, 전문가 에이전트들은 독립적으로 문항에 답하였다. 이렇게 모인 50 개의 의견을 집계하여 하나의 집계된 응답으로 만들었으며 이 과정은 <그림 2>의 (2)에서 설명한다. 또한 무작위성의 영향을 배제하기 위해 각 주제와 LLM 조합별로 실험을 $r=3$ 회 반복하여, 회차 간 찬성 비율이 동일한지를 카이제곱 동질성 검정으로 $H_0: p_1 = p_2 = p_3$ 을 자유도 $df=2$ 로 검정하였다. 다중 조건을 동시에 검정하므로 p-value 는 Holm 보정을 적용하였다. <표 2>의 min_exp 은 각 조건의 분할 표에서 계산된 기대도수 최소값으로, 카이제곱 근사의 적합성을 점검하기 위한 지표이다. 검정 결과, 모든 주제와 LLM 조건에서 유의수준 0.05 에서 기각되지 않아, 회차 효과는 유의하지 않았다 (표 2). 따라서 본 연구에서 사용한 프롬프트와 샘플링 설정 하에서, $r=3$ 회 반복에 따른 집계 결과는 큰 변동 없이 재현 가능함을 관측하였고, 이후 분석에서는 각 조건의 $r=3$ 회 결과의 평균값을 대표값으로 사용하였다 (표 3).

표 2. r 회 반복 당 카이제곱 동질성 검정 결과

주제	모델	p_val	p_adj	min_exp
안락사	GPT-4o-mini	0.91	1.0	4.33
	Gemini-2.5-flash	0.97	1.0	18.67
젠더	GPT-4o-mini	1.00	1.0	0.00
	Gemini-2.5-flash	0.58	1.0	9.00
동물 실험	GPT-4o-mini	0.88	1.0	11.00
	Gemini-2.5-flash	0.47	1.0	12.00
낙태	GPT-4o-mini	0.72	1.0	8.67
	Gemini-2.5-flash	0.86	1.0	12.33

표 3. r 회 반복 당 응답 50 개 중 찬성 개수. 각 횟수에서 큰 차이는 보이지 않은 것으로 확인되었다.

주제	모델	r=1	r=2	r=3	평균
안락사	GPT-4o-mini	45	46	46	45.6
	Gemini-2.5-flash	32	31	31	31.3
젠더	GPT-4o-mini	50	50	50	50
	Gemini-2.5-flash	41	43	39	41
동물 실험	GPT-4o-mini	12	11	10	11
	Gemini-2.5-flash	21	18	24	21
낙태	GPT-4o-mini	43	41	40	41.3
	Gemini-2.5-flash	37	39	37	37.6

(1) 프롬프트

Enter your question: Regardless of whether or not you think it should be legal, please tell me whether you personally believe that in general abortion is morally acceptable or morally wrong. You must pick one side.

(2) 응답

Expert 1: Ethicist

Answer 1: As an ethicist, I believe that abortion is morally acceptable under certain circumstances. The moral status of the fetus is a complex issue, and I argue that a woman's autonomy and right to make decisions about her own body are paramount.

Expert 2: Medical Doctor (Obstetrician)

Answer 2: As an obstetrician, my primary focus is on the health and well-being of my patients. I believe that the moral acceptability of abortion is deeply personal and varies significantly among individuals based on their values, beliefs, and circumstances.

...

Expert 50: Medical doctor

Answer 50: As a medical doctor, my perspective on abortion is rooted in the principles of autonomy, health, and well-being. I believe that abortion is morally acceptable, as it empowers individuals to make decisions about their own bodies and reproductive health.

Final Aggregated Answer: Abortion is generally considered morally acceptable, especially in cases involving health risks, fetal abnormalities, or socio-economic challenges. The autonomy of the individual, particularly women, is a key factor in the moral acceptability of abortion.

그림 2. 프롬프트를 입력으로 넣어(1) 전문가 에이전트와 응답이 생성된 결과(2). 그림에서는 예시 주제로 낙태를 선정하였다.

3.3 데이터 전처리

비교군인 Gallup Poll 은 각 이슈에 대해 “Morally acceptable” 응답 비율을 제시하며, 나머지 응답은 “Morally wrong”, “Depends on situation”, “No opinion”으로 별도 집계하였다. 이에 본 논문에서는 Gallup 의 비율과의 동일한 분모와 비교를 위해, 모델 출력을 찬성과 비찬성으로 정규화하였다. 구체적으로 “대체로 찬성, 지지한다, 허용해야 한다, 금지하지 말아야 한다” 등은 찬성으로 분류하고, “반대, 대체로 반대,

지지하지 않는다, 금지해야 한다, 상황에 따라 다르다, 양측 모두 타당하다, 대답할 수 없다” 등은 비찬성으로 분류하였다. 분류는 본 규칙에 따라 저자가 수동으로 수행하였다.

4 실험 결과

본 섹션에서는 여론조사 결과 분포와 두 LLM 의 응답 분포를 비교하여 어떤 LLM 이 어떤 특정 주제에서 인간과의 응답 차이가 있는지를 평가하였다.

4.1 여론조사 결과 분포와 LLM 전문가 에이전트의 응답 분포 비교

주제별로 어떤 LLM 이 어느 정도의 편향을 가지는지를 알아보기 위해, 네 가지 사회 주제에 대한 LLM 전문가 에이전트의 찬성 비율을 계산하여 <표 4>에 작성하였다. 또한 각 주제별로 여론조사의 통계 찬성 비율과 LLM 전문가 에이전트의 찬성 비율을 비교한 결과를 <표 4>에서 계산하였다. 또한 두 LLM 과 여론조사가 정렬되는지를 점검하기 위해 주제와 LLM 조합별로 두 비율 z-검정을 수행하였다. 이 때 다중 조건 검정에 따른 1 종 오류 누적을 통제하기 위해 Holm 보정을 적용한 p_adj 를 <표 4>에 보고하였다. 검정 결과 8 개 비교 중 6 개 조건에서 인간 찬성 비율과의 차이가 유의하였으며, 특히 젠더, 안락사, 낙태 주제에서 두 LLM 모두 인간 대비 과도하게 많은 찬성 비율을 보였다.

표 4. 두 LLM 과 여론조사 결과의 차이 검정 (p_adj 값이 0.01 보다 작아 통계적으로 유의미함을 나타내기 위해 ** 표시)

주제	여론 찬성 비율	모델	p_model	p_adj
안락사	53.0	GPT-4o-mini	91.3	<0.01**
		Gemini-2.5-flash	62.7	0.054
젠더	44.0	GPT-4o-mini	100.0	<0.01**
		Gemini-2.5-flash	82.0	<0.01**
동물 실험	47.0	GPT-4o-mini	22.0	<0.01**
		Gemini-2.5-flash	42.0	0.256
낙태	49.0	GPT-4o-mini	82.7	<0.01**
		Gemini-2.5-flash	75.3	<0.01**

4.2 LLM 에서 주제별 결과 특성

여론조사 결과로 나온 인간 집단 응답 분포를 기준으로 삼아, 두 LLM 이 인간 분포와 각각 얼마나 상이한지를 살펴보았다. 이를 위해 동일한 문항에서의 GPT-4o-

mini와 Gemini-2.5-flash의 응답을 두 표본 비율 z-검정(양측, $\alpha=0.05$)을 수행하였다. 절차는 다음과 같다: 인간 여론 비율을 p_{human} , 각 LLM의 평균 찬성 비율(3회 반복의 평균)을 p_{gpt} 와 p_{gemini} 로 두고, 각 LLM과 인간 여론 비율의 편차를 다음과 같이 계산하였다.

$$\Delta_{gpt} = p_{gpt} - p_{human}$$

$$\Delta_{gemini} = p_{gemini} - p_{human}$$

같은 주제에 대한 두 LLM 간의 차이 Δ_{diff} 는 앞에서 계산한 Δ_{gpt} 와 Δ_{gemini} 의 차이로 정의하였다.

$$\Delta_{diff} = \Delta_{gpt} - \Delta_{gemini}$$

두 LLM의 인간 대비 편차가 동일한지 검정하기 위해 $H_0: \Delta_{diff} = 0$ 으로 두고, 이에 대한 z 값과 p 값을 산출한 뒤, 두 표본 비율 z-검정(양측, $\alpha=0.05$)을 수행하였다. 이때, 다중비교로 인한 1종 오류 누적을 통제하기 위해 주제 개수에 대해 Holm 보정을 적용하여 p_{adj} 를 보고하였고, 주요 결과를 <표 5>에 정리하였다. 결과적으로, 주제에 따라 LLM 별로 편향 정도가 다르게 나타났으며, 안락사 주제와 젠더 주제에 대해 GPT-4o-mini가 Gemini-2.5-flash보다 찬성 쪽으로 편향된 응답을 보여주었다. 구체적으로, 안락사 주제는 $p_{adj}=0.002$ 로 통계적으로 유의하며 GPT-4o-mini가 더 찬성 쪽으로 편향되었다. 젠더 주제 역시 $p_{adj}=0.007$ 로 차이가 유의하며 GPT-4o-mini가 Gemini-2.5-flash보다 인간 기준 대비 더 찬성 쪽으로 편향되는 것을 확인할 수 있었다. 반면 동물 실험 주제는 $p_{adj}=0.06$ 으로 그 차이가 통계적으로 유의하지 않았지만, 어느 정도의 차이는 확인할 수 있었다(marginally significant). 마지막으로 낙태 주제는 $p_{adj}=0.28$ 로 두 LLM 간의 유의한 차이가 없었다. 종합하면 4개 주제 중 안락사와 젠더 주제에서 GPT-4o-mini가 Gemini-2.5-flash보다 인간 분포 대비 유의하게 더 찬성으로 기우는 편향을 보였고, 낙태와 동물 실험 주제는 LLM 간 차이가 통계적으로 유의하지 않았다.

표 5. 두 LLM 간의 차이 검정 (p_{adj} 값이 0.01 보다 작아 통계적으로 유의미함을 나타내기 위해 ** 표시)

주제	Δ_{gpt}	Δ_{gemini}	Δ_{diff}	z	p_{adj}
안락사	0.38	0.09	0.28	3.40	<0.01**
젠더	0.56	0.39	0.16	3.01	<0.01**
동물 실험	-0.25	-0.05	-0.20	-2.14	0.06
낙태	0.35	0.26	0.08	1.97	0.28

5 논의

5.1 LLM 별, 주제별 편향 양상

우리는 본 연구를 통하여 네 가지 사회 주제 중 젠더와 안락사 주제에 GPT-4o-mini가 Gemini-2.5-flash보다 찬성 쪽으로 유의하게 기운다는 것을 파악했다. LLM으로 사람의 의견을 대변하거나 설문조사를 대신할 때, LLM 편향을 정량적으로 확인해서 특정 하나의 LLM을 선택하기보다는 다수의 LLM family와 동일 family에서의 다양한 버전을 활용하여, 균형 잡힌 응답을 만들어 종합적인 판단을 해야 할 필요가 있음을 검토할 필요가 있다.

5.2 전문가 에이전트 생성 방식에 편향이 있는가?

MEP를 포함한 많은 LLM 프레임워크는 LLM에 과도하게 의존하는 경향을 피할 수 없다. 특히나 본 연구에서 사용한 방법론인 MEP는 전문가 에이전트 생성, 응답 생성, 응답 집계 단계를 하나의 LLM이 전부 수행하기 때문에, 더 객관적이고 다양한 관점을 가지는 전문가 에이전트를 생성하는 방법론이 필요하다.

5.3 한계점 및 향후 연구

본 연구에는 세 가지 한계점이 있다. 첫째, 본 연구에서는 GPT-4o-mini와 Gemini-2.5-flash 모델 두 가지를 사용하였으나, 앞으로는 다양한 버전의 LLM을 실험해 볼 필요성이 있다. 둘째, GPT-4o-mini와 Gemini-2.5-flash는 오픈소스 모델이 아니기 때문에 전문가 에이전트 수를 50명으로 설정하였으나, 50명이 적절한 수인지는 향후 연구에서 더 검증해 볼 필요성이 있다. 셋째, 안락사, 젠더, 동물 실험, 낙태 이외의 더욱 다양한 주제에서 연구가 필요하다. 추후에 더 다양한 LLM의 버전과 계열을 고려하고, 전문가 에이전트 수와 주제 수를 확장하여 실험을 진행함으로써 LLM 응답의 편향을 강건하고 설득력 있게 검증할 수 있을 것이다.

6 결론

본 연구는 인간 참가자를 대체하여 LLM으로 설문조사를 진행하기 전, LLM 편향을 정량적으로 확인하여 다양한 LLM과 LLM family를 활용하여 균형 잡힌 응답을 만들어야 할 필요성을 확인하였다. 이는 사회 과학 분야에서 점차 더 많은 연구가 실제 인간 여론조사가 아닌 LLM 에이전트를 대상으로 한 여론조사를 사용하여 진행될 것이라는 점에서 중요한 고려 사항이 된다. 본 논문에서는 Holm 보정을 사용한 두 표본 z-검정을 사용하여 두 LLM의 주제별 편향을 체계적으로 비교하고 분석하여 LLM 별, 주제별 응답 차이를 증명하였다. 우리는 향

후 더욱 다양한 조건과 주제로 실험함으로써 LLM 과 인간 정렬을 더 나은 방향으로 개선할 수 있는 방향을 찾고자 한다. 이를 바탕으로, 본 연구의 지표와 절차가 LLM 을 설문 응답자로 사용하기 전에, 주제별 편향을 사전 점검하고 사용 여부를 결정하는 단계에 활용되기를 기대한다.

7 사사의 글

이 논문은 2025 년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원 (No.RS-2020-II201373,인공지능대학원지원(한양대학교)) 및 정부(교육부)의 재원으로 한국산업기술진흥원의 지원을 받아 수행된 연구임 (P0030395, 첨단산업인재양성부트캠프).

참고 문헌

1. Aher, G. V. et al. Using large language models to simulate multiple humans and replicate human subject studies. In Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA, pp. 337 – 371. 2023.
2. Argyle, L. P. et al. Out of one, many: Using language models to simulate human samples. Political Analysis. 31(3). Cambridge University Press. pp. 337 – 351. 2023.
3. Dillion, D. et al. Can AI language models replace human participants? Trends in Cognitive Sciences. 27(7). Elsevier Ltd. pp. 597 – 600. 2023.
4. Dominguez-Olmedo, R. et al. Questioning the survey responses of large language models. In Advances in Neural Information Processing Systems. Vancouver, Canada, pp. 45850 – 45878. 2024.
5. Santurkar, S. et al. Whose opinions do language models reflect? In Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA, pp. 29971 – 30004. 2023.
6. Long, D. X. et al. Multi-expert prompting improves reliability, safety and usefulness of large language models. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami, Florida, USA, pp. 20370 – 20401. 2024.
7. Du, Y. et al. Improving factuality and reasoning in language models through multiagent debate. In Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria, pp.11733 – 11763. 2024
8. Newport, F. Trends in Adults' Acceptance of Moral Values and Behaviors. <https://news.gallup.com/opinion/polling-matters/694550/trends-adults-acceptance-moral-values-behaviors.aspx> November 21, 2025.
9. Brenan, M. Slim Majority of Adults Say Changing Gender Is Morally Wrong. <https://news.gallup.com/poll/645704/slim-majority-adults-say-changing-gender-morally-wrong.aspx> November 21, 2025.